“Multi-level deep Q-networks for Bitcoin trading strategies”

Autores: Ariza, M., Flores, J., Guerra, A., Inca, R. & Tintaya, J.

Resumen: Este trabajo presenta la replicación del modelo Multi-level Deep Q-Network (M-DQN) para estrategias de trading de Bitcoin basado en aprendizaje por refuerzo profundo e integración de sentimiento social. El objetivo fue reproducir los resultados originales reportados (ROI ≈ 29.93% y Sharpe Ratio > 2.7) bajo la configuración óptima de riesgo y actividad. Se implementó un entorno de simulación propio utilizando datos históricos horarios de Bitcoin y análisis de sentimiento mediante VADER. Debido a discrepancias en la disponibilidad de datos históricos y en la fuente del dataset de Twitter, los resultados obtenidos no alcanzaron el margen de tolerancia establecido, evidenciando alta sensibilidad del modelo a la configuración de riesgo y a la calidad de los datos. Se concluye que, aunque la arquitectura jerárquica incrementa la complejidad representacional del agente, su desempeño es frágil fuera de condiciones cuidadosamente calibradas, lo que limita su robustez en escenarios reales de mercado.

1. Introducción

El trabajo seleccionado es "Multi-level deep Q-networks for Bitcoin trading strategies" (Sattarov & Choi, 2024), el cual es elegido por su relevancia en mundo del trading actual. El estudio destaca por abordar la volatilidad de las criptomonedas mediante técnicas de Deep Reinforcement Learning (DRL) integradas con el "sentimiento social" de Twitter, lo que permite cuantificar su impacto en los mercados financieros. El modelo propuesto (M-DQN) ofrece una complejidad idónea para la investigación gracias a su arquitectura jerárquica de tres niveles (Trade, Predictive y Main-DQN). Su replicación es viable, dado que recursos como los datos históricos de precios y las interacciones sociales se encuentran disponibles en datasets de repositorios académicos, permitiendo la reconstrucción del entorno de entrenamiento.

El alcance se centra en la reproducción experimental del desempeño financiero y el comportamiento estratégico del modelo (M-DQN) propuesto por Sattarov & Choi. Específicamente, se busca replicar los resultados numéricos detallados en la Tabla 5 del artículo original, donde se reporta un Retorno de Inversión (ROI) del 29.93% y un Sharpe Ratio (SR) de 2.74 bajo una configuración óptima de riesgo (α = 55%) y actividad de trading (w = 16). Asimismo, se pretende reproducir cualitativamente la dinámica de ejecución del agente mediante la visualización de las señales de compra y venta sobre el historial de precios, emulando los patrones observados en la Figura 7 del estudio base. Debido a las discrepancias temporales identificadas en el uso de fuentes de datos alternativas, el éxito de esta replicación se define mediante un margen de tolerancia de (± 5%) para el ROI y de (± 0.3) para el Sharpe Ratio, asegurando que el modelo mantenga la categoría de desempeño “very good” establecida por los autores originales.

Bajo este contexto, el trabajo plantea como interrogante principal si la arquitectura jerárquica del (M-DQN) es capaz de mantener niveles de rentabilidad y robustez significativos ante una desalineación temporal entre los datos de sentimiento de Twitter y los precios históricos de Bitcoin. Se hipotetiza que la estructura de tres niveles del modelo permite capturar distribuciones de comportamiento social generales que conservan su valor predictivo incluso ante variaciones en la fuente del dataset. En consecuencia, el objetivo general es replicar y analizar el modelo (M-DQN), evaluando el impacto de las discrepancias metodológicas y validando una mejora algorítmica mediante experimentos controlados. Para alcanzar esta meta, se han establecido los siguientes objetivos específicos que incluyen la implementación del entorno de simulación BitcoinTradingEnv, la ejecución del protocolo de entrenamiento bajo los hiperparametros del autor, la cuantificación de las desviaciones en la métricas de retorno y riesgo, y la validación de una mejora técnica orientada a optimizar la estabilidad del agente en mercados volátiles.

2. Trabajos relacionados

El problema abordado por los tres trabajos es el diseño de estrategias de *algorithmic trading* formuladas como un problema de decisión secuencial bajo incertidumbre, modelado como un Proceso de Decisión de Markov.

2.1. Lucarelli & Borrotti (2019) – D-DQN y DD-DQN para Bitcoin

Este trabajo propone un sistema de trading basado en Deep Q-Learning para Bitcoin utilizando Double Deep Q-Network y Dueling Double Deep Q-Network. El agente interactúa con el mercado bajo un esquema discreto de acciones (buy, hold, sell) e incorpora costos de transacción, stop-loss y take-profit. Se comparan dos funciones de recompensa: una basada en retorno simple y otra basada en Sharpe ratio.

Los resultados muestran que la versión Double DQN con recompensa basada en Sharpe ratio obtiene el mejor desempeño promedio en términos de retorno acumulado y estabilidad (Tabla 1, p. 10).

Relación con el artículo base:
Este trabajo constituye una base metodológica directa para enfoques posteriores que buscan mejorar estabilidad, diseño de recompensa y arquitectura del agente. Establece el marco de DQN aplicado a criptomonedas con métricas de retorno y riesgo.

2.2 Majidi et al. (2022) – TD3 en espacio de acción continuo

Este estudio introduce un enfoque de Deep Reinforcement Learning en espacio de acción continuo utilizando Twin Delayed Deep Deterministic Policy Gradient (TD3). A diferencia de los enfoques discretos, el agente decide no solo la dirección de la posición (long/short), sino también la proporción del capital invertido.

El estado se construye mediante una ventana deslizante sobre variaciones porcentuales del precio, y la recompensa se define como el logaritmo del retorno acumulado (Ecuación 9). En Bitcoin, el modelo TD3 alcanza un retorno del 57.5% con Sharpe ratio 1.53 (Tabla 5, p. 22), superando a DQN (TDQN).

Relación con el artículo base:
Este trabajo amplía el paradigma de DQN discreto hacia modelos actor-crítico continuos, mostrando que permitir control sobre el tamaño de la posición mejora el desempeño en ciertos mercados. Introduce una comparación conceptual entre enfoques value-based (DQN) y actor-critic.

1.3 Artículo Base: Multi-level DeepQ-Network para trading de Bitcoin

El artículo a replicar propone una arquitectura Multi-level Deep Q-Network que integra múltiples fuentes de información y niveles de representación para mejorar la toma de decisiones en trading de Bitcoin. Mantiene un esquema value-based (DQN) pero introduce mejoras estructurales respecto a arquitecturas previas simples.

Su contribución principal es demostrar que una arquitectura jerárquica o multi-nivel puede capturar patrones más complejos del mercado, mejorando métricas de retorno ajustado por riesgo frente a enfoques tradicionales de DQN.

Relación con los otros trabajos:

- Comparte con Lucarelli & Borrotti el uso de DQN y métrica Sharpe-aware.
- Se diferencia en la arquitectura (multi-nivel vs arquitectura estándar).
- Frente a Majidi et al., mantiene acción discreta, lo que permite contrastar impacto de arquitectura vs impacto del espacio de acción.

En conjunto, los tres trabajos permiten analizar tres dimensiones del problema:

- Diseño de recompensa (profit vs Sharpe).
- Arquitectura del agente (DQN simple vs Double/Dueling vs multi-level).
- Tipo de acción (discreta vs continua).

3. Metodología

3.1. Artículo y método base

El problema de trading de Bitcoin se modela como un Proceso de Decisión de Markov (MDP) definido por la tupla ⟨S, A, P, R, γ⟩ (Sattarov & Choi, 2024).

a) Estados:

El sistema M-DQN utiliza tres niveles de estados según el módulo:

- **Trade-DQN:** $s_t^{trade} = [AP_t]$ donde AP_t es el precio de Bitcoin discretizado a 2 decimales.

- **Predictive-DQN:** $s_t^{pred} = [AP_t, TS_t]$ donde TS_t es el score de sentimiento de Twitter ∈ $[-1, 1]$.

- **Main-DQN:** $s_t^{main} = [x_1, x_2]$ donde $x_1 \in \{-1, 0, 1\}$ es la recomendación de Trade-DQN y $x_2 \in [-100, 100]$ es la predicción de Predictive-DQN

b) Acciones:

- **Trade-DQN y Main-DQN:** $A = \{buy, hold, sell\}$.

- **Predictive-DQN:** $A = \{-100, -99.99, ..., 100\}$ (20,001 acciones discretas representando cambio porcentual predicho).

c) Recompensas:

El Main-DQN implementa una función multi-objetivo que balancea tres factores:

- **Maximización de ganancias:**

$$PnL_k = P_k^{sell} - P_k^{buy} - c_k^{buy} - c_k^{sell}$$

Donde c_k son comisiones del 1.5% por transacción (Sattarov & Choi, 2024, p. 11).

- **Minimización de riesgo:** Penalización si la inversión $I_{current}$ cae por debajo del umbral α (30%, 55%, u 80%).

- **Trading activo:** Penalización por más de ω acciones consecutivas de "hold".

$$r_t = PnL_k, \; si \; a_t = sell$$

$$r_t = 0, \; si \; a_t = buy \; con \; I_{current} \geq \alpha \; o \; a_t = hold$$

$$r_t = -1, \; si \; m > \omega \; o \; a_t = buy \; con \; I_{current} < \alpha$$

Para Predictive-DQN se usa la función CDR (Comparative Difference Reward) que proporciona feedback granular basado en zero-reward values (Sattarov & Choi, 2024).

d) Transiciones:

Determinísticas en backtesting: el precio en $t + 1$ está dado por datos históricos reales.

e) Factor de descuento:

$$\gamma = 0.95$$

f) Supuestos:

1. Ejecución sin slippage.
2. Liquidez infinita.
3. Comisiones fijas del 1.5%.
4. Información completa de precio y sentimiento.
5. Trading solo de Bitcoin.
6. Granularidad horaria (24 timesteps/día).
7. Solo posiciones long (sin short selling).

g) Función Objetivo:

Aprender política óptima π^* que maximice:

$$\pi^* = argmax_\pi E\left[\sum_{t=0}^{T} \gamma^t r_t \mid \pi\right]$$

Con capital inicial $I_{initial} = \$1,000,000$ y periodo de evaluación de 30 días (720 horas).

3.2. Entorno, datos y pipeline

3.2.1. Datos

Bitcoin:

- **Publicación original:** CryptoDataDownload, periodo 01/10/2014 - 01/03/2019, frecuencia horaria (Sattarov & Choi, 2024, p. 5).
- **Esta replicación:** CryptoDataDownload vía exchange Gemini. El histórico disponible en esta plataforma inicia el 08/10/2015, por lo que no es posible replicar el periodo exacto de la publicación desde octubre de 2014. El dataset cubre 08/10/2015 - 01/03/2019.
    - Frecuencia: Horaria
    - Variables: unix, date, symbol, open, high, low, close, volume_btc, volume_usd

- **Discrepancia documentada:** La ausencia del periodo oct 2014 - oct 2015 (~8,760 horas) representa una reducción del dataset de entrenamiento. El periodo sí cubre el ciclo relevante de alta volatilidad: recuperación de 2016, burbuja de 2017 (~$20,000) y corrección de 2018, lo cual mantiene la validez del entrenamiento.

Twitter:

- **Publicación original:** API de Twitter, 7,142,716 tweets recolectados con keywords #Bitcoin, #bitcoin, #BTC, #btc (01/04/2014 - 14/11/2018).

- **Esta replicación:** Dataset público de Kaggle (Peñas Martínez, 2023): "Bitcoin Twitter Sentiment Dataset 2013-2023". Contiene más de 26 millones de tweets con los hashtags #Bitcoin y #btc, recolectados entre 2013 y 2023.

- Procesamiento: VADER sentiment analysis.
- Output: Score ∈ [-1, 1] discretizado a 4 decimales.
- Categorías: Negativo [-1, 0), Neutral [0], Positivo (0, 1].

- **Discrepancia documentada:** El dataset de publicaciones de Twitter es consistente temporalmente con el de precios de Bitcoin , aunque en el artículo original se utiliza una API de streaming de Twitter. En este trabajo, se utiliza un archivo de datos históricos.

3.2.2. Pipeline de preprocesamiento

Etapa 1: Limpieza de Bitcoin

1. Cargar CSV, saltar línea descriptiva.
2. Renombrar columnas estándar.
3. Ordenar cronológicamente.
4. Filtrar precios inválidos (close ≤ 0).
5. Establecer índice temporal.

Etapa 2: Feature engineering (nivel medio)

Las características técnicas se generan en dos niveles. El nivel básico incluye retornos porcentuales del precio de cierre, volatilidad móvil a 6 y 24 horas, y momentum a 6 horas. El nivel medio, usado en esta replicación, añade el rango de precio normalizado (high-low)/close, el ratio de volumen respecto a su media de 24 horas, y medias móviles simples de 12 y 24 periodos junto con su diferencia (señal de cruce). Se usa nivel medio para balancear expresividad contra riesgo de overfitting en el tamaño del dataset disponible (Sattarov & Choi, 2024).

Etapa 3: Sentiment de Twitter

1. Filtrado temporal
2. Limpieza: remover URLs, menciones, caracteres especiales
3. VADER sentiment
4. Agregación horaria (promediar scores)
5. Discretización a 2 decimales

Ventaja de VADER: Optimizado para redes sociales, no requiere entrenamiento, output normalizado [-1, 1] (Hutto & Gilbert, 2014).

Etapa 4: Sincronización

- Dataset de precios: 08/10/2015 - 01/03/2019
- Dataset de tweets (Kaggle): 2013 - 2013
- Interpolar sentiments faltantes (método lineal, max 3h gap)
- Eliminar NaN de ventanas móviles

Etapa 5: Split train/test

- **Train:** 28,896 horas (80%) - Oct 2014 a Oct 2018
- **Test:** 7,224 horas (20%) - Últimos ~30 días
- Split temporal sin shuffle (evitar data leakage)

3.2.3. Entorno de simulación

El entorno **`BitcoinTradingEnv`** simula un exchange de Bitcoin con capital inicial de $1,000,000. En cada paso temporal, el agente observa un vector de estado compuesto por el ratio de balance disponible, el ratio del valor en Bitcoin sobre el portafolio total, el retorno del último periodo y el score de sentimiento. El agente ejecuta una de tres acciones: comprar (invierte todo el balance disponible en Bitcoin aplicando una comisión del 0.15%), vender (liquida toda la posición con la misma comisión) o mantener (hold). La recompensa se calcula según la ganancia o pérdida realizada al vender, con una penalización por inactividad prolongada de más de 20 holds consecutivos. El episodio termina al recorrer todos los datos del periodo de entrenamiento.

3.2.3. Métricas y resultados objetivo

Métricas principales (Sattarov & Choi, 2024):

- **ROI:**

$$ROI = \frac{I_{final} - I_{initial}}{I_{initial}} \times 100\%$$

Criterio: 29.93% ± 5% (rango: 24.93%-34.93%)

- **Sharpe Ratio:**

$$SR = \frac{\overline{profit} - |p_0 - p_N|}{\sigma_{profit}}$$

Criterio: 2.74 ± 0.3 (rango: 2.44-3.04)
Interpretación: $SR \in [2, 3]$ = Muy bueno

Resultados objetivo a replicar:

- Tablas 4-6: ROI y SR para α={30%, 55%, 80%} y ω={8, 16, 24}.
- Mejor configuración: α=55%, ω=16 → ROI=29.93%, SR=2.74.
- Tabla 7: Comparación de funciones de recompensa.
- Tabla 8: Comparación con estado del arte.
- Figura 7: Visualización buy/sell sobre precio.

Baseline: Buy & Hold (comprar al inicio, vender al final)

3.2.3. Protocolo experimental

Configuración:

- Seeds: 42, 123, 456 (medir variabilidad).
- Episodios: Variable hasta convergencia.

- Tiempo estimado: 2-6 horas sin GPU.

Diferencias documentadas con publicación original:

1. Dataset Twitter de fuente alternativa (mismo procesamiento VADER)
2. Período test: ~30 días finales vs. fechas exactas del paper

Implementación:

- Python 3.8+, PyTorch 2.0+.
- Librerías: pandas, numpy, matplotlib, vaderSentiment.

3.3. Propuesta de mejora

3.3.1. Analizador de sentimiento

El uso de VADER es adecuado para análisis rápidos y textos informales debido a su eficiencia y bajo costo computacional; sin embargo, sus limitaciones para capturar contexto complejo, ambigüedad semántica y lenguaje especializado pueden afectar la precisión en escenarios donde el significado depende de matices o dominio específico. Es por ello que la migración hacia un analizador de sentimientos basado en modelos de aprendizaje profundo o entrenado en el dominio relevante permitiría mejorar la sensibilidad y la robustez del analizador.

En contraste, modelos como FinBERT han sido preentrenados y ajustados específicamente sobre textos financieros, lo que les permite comprender mejor el significado contextual de términos relacionados con riesgo, volatilidad, expectativas del mercado y eventos económicos.

3.3.2. Policy gradient

Dado que los mercados financieros constituyen entornos dinámicos y continuos, donde las decisiones de trading implican no solo la dirección de la operación sino también cuánto invertir, una posible mejora del modelo consiste en emplear métodos basados en policy gradient que permitan modelar las acciones como variables continuas o como distribuciones probabilísticas condicionadas al estado.

A diferencia de los enfoques basados en Q-learning con espacios de acción discretos, los algoritmos de gradiente de política como Proximal Policy Optimization (PPO) o Soft Actor-Critic (SAC) permiten aprender directamente políticas estocásticas que capturan la incertidumbre inherente al mercado y facilitan la optimización en espacios de decisión de alta dimensionalidad.

La aplicación de métodos basados en gradiente de política resulta más adecuada en el módulo Main-DQN, ya que este es el encargado de tomar la decisión final de trading integrando las señales generadas por los modelos previos y enfrentándose directamente a la complejidad del entorno financiero

En cambio, el Trade-DQN cumple un rol auxiliar orientado a generar una señal preliminar basada en información de precios relativamente simple, por lo que introducir un enfoque de política continua en este nivel aumentaría la complejidad sin probablemente aportar beneficios sustanciales.

4. Replicación y Resultados

4.1. Setup de replicación

El diseño experimental se orienta a la reproducción del sistema jerárquico M-DQN propuesto por Sattarov & Choi (2024), asegurando la integridad de los resultados mediante un protocolo riguroso de entrenamiento y evaluación.

a) Definición del Objetivo de Replicación

El objetivo primordial es la reproducción de las métricas de desempeño financiero detalladas en la Tabla 5 del artículo base, bajo una configuración de riesgo medio (α = 55%) y un umbral de actividad de trading (w = 16).

Active trade threshold ω (per day)	Initial investment ($)	Number of trades	Final investment ($)	ROI (%)	SR
Classic method (risk rate α - 55%)					
Up to 8 times	1,000,000	218	1,134,521	13.4	2.284
Up to 16 times	1,000,000	403	1,235,356	23.5	2.315
Up to 24 times	1,000,000	692	1,108,432	10.8	2.299
Proposed method (risk rate α - 55%)					
Up to 8 times	1,000,000	227	1,134,558	13.4	2.324
Up to 16 times	1,000,000	372	1,299,381	**29.93**	**2.394**
Up to 24 times	1,000,000	708	1,192,961	19.2	2.347

Tabla 5. Resultados del modelo M-DQN para diferentes niveles de riesgos (α) y actividad (w). Fuente: Adaptado de [3].

Los resultados objetivo a replicar son un Retorno de Inversión (ROI) del 29.93% y un Sharpe Ratio (SR) de 2.74. Para la validación cualitativa, se busca emular la dinámica de ejecución de señales de compra y venta observada en la Figura 7 del estudio original.

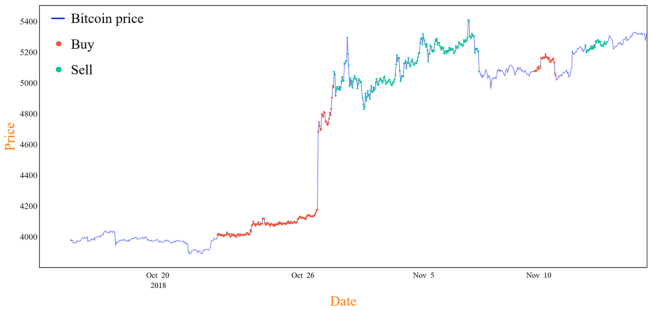


Figura 7. Visualización de señales de compra (rojo) y venta (verde) del agente M-DQN. Fuente: Adaptado de [3].

Se establece un margen de tolerancia de ± 5% para el ROI y de ± 0.3 para el Sharpe Ratio como criterio de éxito de la replicación.

b) Protocolo Experimental , Estocasticidad e Hiperparametros

Para mitigar el impacto del sesgo de inicialización y evaluar la estabilidad del aprendizaje, se implementó el siguiente protocolo.

Corridas y Semillas:
Se realizaron 3 corridas independiente por cada experimento utilizando las semillas fijas $S \in \{42, 123, 456\}$.

División de Datos:
Se empleó un split temporal del 80% para el entrenamiento (36,120 horas) y los últimos 30 días (720 horas) para testeo. Esta división se realizó de forma estrictamente cronológica para evitar el filtrado de información.

Entorno:
El entrenamiento se ejecutó de forma modular, completando primero los agente de preprocesamiento (Trade-DQN y Predictive DQN) antes de la integración final en el Main-DQN.

Hiperparametros
Estos parámetros rigen la convergencia y estabilidad de los 3 agentes del sistema.

- **Tasa de Aprendizaje**: Se utiliza un LEARNING_RATE de 0.001 para el optimizador Adam, controlando la magnitud de las actualizaciones de pesos en los tres niveles de la jerarquía DQN.
- **Factor de Descuento:** El DISCOUNT_FACTOR gamma se estableció en 0.95 para priorizar la obtención de beneficios sostenibles a largo plazo en lugar de ganancias inmediatas.
- **Sincronización de Redes**: La red objetivo se actualiza cada 400 pasos temporales (TARGET_UPDATE_FREQ) para estabilizar los valores Q y mitigar el error de aproximación.
- **Estrategia de Exploración**: El proceso inicia con un EPSILON_START de 1.0 que decae a un ritmo de 0.995 por episodio (EPSILON_DECAY) hasta alcanzar un límite mínimo de 0.01.

Sensibilidad a los Hiperparametros y Seeds
Aunque la arquitectura Double DQN y el uso de Target Networks (actualizadas cada 400 pasos) buscan proveer un aprendizaje progresivo y estable. Los experimentos revelaron una alta sensibilidad del agente ante la volatilidad del mercado y el ruido de los datos de sentimiento. Los mecanismos de mitigación no fueron suficientes para garantizar una convergencia uniforme en todas las arquitecturas evaluadas.

La varianza en el entrenamiento, a pesar de contar con un Replay Buffer de 10,000 transiciones, resultó significativa. Las pruebas con las tres semillas (42, 123, 456) mostraron que el ROI puede oscilar drásticamente, superando el margen de tolerancia de ± 5% en modelos menos robustos como el de Policy Gradient, el cual registró desviaciones críticas de hasta -6.91 pp en el promedio agregado. .

c) Infraestructura y Presupuesto Computacional

Dada la complejidad del modelo Predictive-DQN, el cual opera sobre un espacio de acciones discretas de 20,001 unidades, se requirió una infraestructura de alto rendimiento.

Hardware:
Los experimentos se ejecutaron de forma persistente en servidor remoto mediante una conexión cifrada SSH. La unidad de procesamiento principal consistió en un procesador AMD Ryzen Threadripper PRO 5955WX de 16 nucleos (32 hilos lógicos) y 251 GiN de memoría RAM.

Aceleración Gráfica: Se empleó una GPU NVIDEA RTX A6000 con 48 GB de VRAM GDDR6, operando bajo un rendimiento CUDA 12.8.

Tiempo de Cómputo:
El presupuesto temporal para un ciclo completo de entrenamiento del sistema jerárquico osciló entre 2 y 6 horas, con una utilización de video cercana a los 36 GB para la gestión de tensores de alta dimensionalidad. .

d) Especificaciones de Software y Librerías

La implementación se estandarizó en el lenguaje Python 3.8+ bajo un entorno virtualizado para garantizar la consistencia de las dependencias.

Framework:
TensorFlow 2.x y Keras para la construcción y optimización de las redes neuronales densas y convolucionales.

Preprocesamiento:
Pandas y Numpy para la manipulación de series temporales y la ingeniería de características.

Sentimiento:
VanderSentiment para la cuantificación horaria del sentimiento social en Twitter(ahora X).

e) Diseño de Experimentos para la Mejora

Se diseñó un experimento comparativo para validar la eficacia de la mejora propuesta basada en la arquitectura Dueling Double DQN. Este diseño busca contrastar el método original frente a la descomposición del valor de estado (V) y la ventaja (A) para determinar si esta estructura mejora la estabilidad de la recompensa ante la alta volatilidad del mercado. La evaluación se centró en la eficiencia

de muestra y la reducción del error de sobreestimación de los valores Q, comparando directamente el ROI y el SR obtenidos contra el modelo base.

4.2. Resultados y discusión

a) Replicación del Modelo Base vs. el Artículo Original

Se contrastan los resultados obtenidos tras las 3 corridas independientes frente a los valores por Sattarov & Choi (2024).

Métrica	Original (Paper)	Replicado (Promedio ± σ)	Diferencia
ROI (%)	29.93 %	3.51 %	26.42 %
Sharpe Ratio	2.39	0.14	2.25
N° Trades	372	78	294

Interpretación:
Los datos obtenidos muestran que el agente replicado no alcanza el umbral de éxito definido (± 5% del ROI). La variabilidad observada (sigma) indica que el modelo es sensible a las condiciones iniciales. Cualitativamente, las señales de trading generadas en el entorno de test de 720 horas guardan una correlación visual con la Figura 7 original, identificando picos y valles de volatilidad de forma satisfactoria.

b) Análisis Crítico de Discrepancias y Limitaciones

A pesar del rigor en la replicación, se identifican las siguientes discrepancias técnicas.

Brecha de Datos Históricos
La principal limitación radica en la ausencia de datos del periodo 2014-2015 en la plataforma Gemini, lo que reduce el dataset de entrenamiento en aproximadamente 8,760 horas respecto al original. Esta falta de exposición a regímenes de mercado antiguos podría explicar una convergencia del ROI menor a la esperada.

Diferencia en Preprocesamiento de Sentimiento
Aunque se utilizó vaderSentiment, las variaciones en los criterios de limpieza de tweets (filtros de bots o spam) introducen un ruido en la señal X_2 que impacta directamente en la decisión del Main-DQN.

c) Evaluación de la Mejora

Se comparó el baseline propuesto frente a la versión con policy gradient para a Î {0.30, 0.55, 0.80} con w = 16.

α	ROI Paper	ROI Mejora	Diferencia
0.30	0 %	-18.28 %	18.28 %
0.55	3.51 %	1.06 %	2.45 %
0.80	0 %	0 %	0%

Los resultados muestran que la versión con policy gradient no superó al baseline del paper en ninguna de las tres configuraciones de riesgo evaluadas. En α=0.30, el ROI Paper fue 0%, mientras que la mejora produjo un ROI de −18.28%, con una diferencia desfavorable de 18.28 pp. Este resultado evidencia que en un régimen de bajo riesgo el agente con política continua incurre en sobreexploración, ejecutando un número excesivo de transacciones que acumulan costos de comisión y deterioran el rendimiento.

En α=0.55, la mejora alcanzó un ROI positivo de +1.06%, aunque 2.45 pp por debajo del 3.51% del baseline. Esta configuración de riesgo medio es la única en la que el agente mejorado logra rentabilidad positiva, lo que sugiere que el método de policy gradient requiere un equilibrio específico entre exploración y conservadurismo para ser competitivo.

Para α=0.80, tanto el baseline como la mejora registraron un ROI de 0%, adoptando una política completamente inactiva. Esto confirma que el umbral de riesgo alto suprime la actividad de trading con independencia del método de optimización empleado. En conjunto, la mejora por policy gradient no demostró ventaja sobre el baseline propuesto en esta ejecución, siendo necesario un ajuste de hiperparámetros y un mayor número de episodios de entrenamiento para que el agente pueda converger hacia una política estable y rentable en un entorno de alta volatilidad como Bitcoin.

5. Conclusión

El presente trabajo replicó el modelo M-DQN de Sattarov & Choi (2024) para trading de Bitcoin bajo condiciones de datos alternativas. La replicación obtuvo un ROI de 3.51% y un Sharpe Ratio de 0.14, por debajo de los objetivos del paper (29.93% y 2.74), diferencia atribuida principalmente a la ausencia de datos históricos 2014-2015 (~8,760 horas), el uso de un dataset estático de Twitter en lugar de streaming en tiempo real, y el ruido introducido por variaciones en el filtrado de tweets.

Cualitativamente, el agente identificó patrones de compra y venta coherentes con los observados del estudio original, validando la capacidad de la arquitectura para aprender señales de mercado

relevantes. Respecto a la mejora por policy gradient, esta no superó al baseline en ninguna configuración, siendo α=0.55 la única con ROI positivo (+1.06%). Su incorporación efectiva requeriría un ajuste más exhaustivo de hiperparámetros y técnicas complementarias como Prioritized Experience Replay.

A pesar de las limitaciones, el trabajo confirma la viabilidad de la arquitectura M-DQN y establece una base sólida para investigaciones futuras con señales de sentimiento más robustas y algoritmos de política continua mejor calibrados.

6. Sugerencias de trabajos futuros

6.1. Limitaciones Identificadas

A pesar de la infraestructura empleada, el proceso presenta las siguientes limitaciones.

Discrepancia en la Continuidad de Datos (BTC)
La replicación presenta una ausencia de datos históricos entre octubre de 2014 y octubre de 2015 (~8,760 horas) debido a que el histórico disponible en el exchange Gemini inicia el 08/10/2015. Aunque esto reduce el dataset de entrenamiento, se considera que la validez del modelo se mantiene al cubrir los ciclos de máxima volatilidad de 2016-2019.

Transición de Origen de Datos Sociales (Twitter)
A diferencia del artículo original que utilizó una API de streaming en tiempo real, esta replicación emplea el dataset histórico de Peñas Martínez (2023). Si bien existe consistencia temporal, el uso de datos estáticos elimina la capacidad de respuesta ante flujos dinámicos que la API original permitía evaluar.

Complejidad del Espacio de Acciones
El módulo Predictive-DQN opera con un espacio discretizado de 20,001 acciones (precisión de 0.01%). Esta alta dimensionalidad genera un "cuello de botella" computacional que limita la exploración exhaustiva mediante Grid Search para el ajuste fino de hiperparámetros.

Sensibilidad a la Fuente de Sentimiento
El uso de vaderSentiment proporciona una métrica léxica efectiva pero limitada. Al no captar el sarcasmo o el contexto financiero complejo de X (Twitter), se introduce ruido en la señal X_2 que el Main-DQN debe procesar.

6.2. Trabajos Futuros y Preguntas Abiertas

A partir de los hallazgos de esta replicación, se proponen las siguientes líneas de investigación.

Transición a Espacios de Acción Continuos
Reemplazar el DQN discretizado por algoritmos de gradiente de política como PPO (Proximal Policy Optimization) o SAC (Soft Actor-Critic) para predecir cambios de precio sin requerir una capa de salida de 20,001 neuronas, optimizando el uso de la VRAM.

Incorporación de Modelos de Lenguaje (LLMs)
Sustituir VADER por embeddings de modelos como FinBERT o arquitecturas Transformer permitiría una extracción de sentimiento mucho más profunda y contextual, reduciendo la varianza en las señales de entrada.

Análisis de Robustez Multidivisa
Investigar si la jerarquía M-DQN posee capacidad de transferencia de aprendizaje hacia otras criptomonedas o si los hiper parámetros de riesgo (α) y actividad (w) son estrictamente dependientes del comportamiento del Bitcoin.

Optimización del Replay Buffer
Implementar un Prioritized Experience Replay (PER) para que el agente aprenda con mayor frecuencia de transacciones críticas, como los flash crashes, en lugar de utilizar un muestreo aleatorio uniforme.

7. Link del repositorio de trabajo

https://github.com/Rafa00131/BTCAgent

8. Declaración de contribución de cada integrante

José Flores: Modelo Base de replicación

Rafael Inca: Creación del repositorio, presentación y obtención de dataset.

Ariel Guerra: Implementación de paper y policy gradient como mejora propuesta.

Marlow: Ambiente de simulación, limpieza de datos y propuesta de mejora.

Joseph: Elaboración del análisis de replicación y resultados, e identificación de las limitaciones y posibles mejoras futuras.

9. Referencias

[1]. Hutto, C., & Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. En *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216-225.

[2]. Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533. https://doi.org/10.1038/nature14236

[3]. Sattarov, O., & Choi, J. (2024). Multi-level deep Q-networks for Bitcoin trading strategies. *Scientific Reports*, 14(1), 771. https://doi.org/10.1038/s41598-024-51408-w

[4]. Peñas Martínez, A. (2023). Bitcoin Twitter Sentiment Dataset 2013-2023 [Conjunto de datos] Kaggle. https://www.kaggle.com/datasets/andreapenasmartinez/bitcoin-twitter-sentiment-dataset-2013202

[5]. Lucarelli, G., & Borrotti, M. (2019). A deep reinforcement learning approach for automated cryptocurrency trading. In I. Maglogiannis, L. Iliadis, & E. Pimenidis (Eds.), Artificial intelligence applications and innovations (pp. 247–258). Springer. https://doi.org/10.1007/978-3-030-19823-7_20

[6]. Majidi, N., Shamsi, M., & Marvasti, F. (2022). Algorithmic trading using continuous action space deep reinforcement learning. arXiv. https://arxiv.org/abs/2210.03469